

# REGULARIZACIÓN PARA DEEP LEARNING:

MODIFICACIÓN QUE HACEMOS A UN ALGORITMO DE APRENDIZAJE, QUE INTENTA REDUCIR SU ERROR GENERALIZADO, PERO NO SU ERROR DE ENTRENAMIENTO.

→ Restricciones y Sanciones

→ Sanciones de la norma de parámetros:


Los modelos lineales (regresión lineal y logística) permiten estrategias de regularización SIMPLES, DIRECTAS y EFECTIVAS.

$$\tilde{J}(\theta; X, y) = J(\theta; X, y) + \alpha \Omega(\theta) \quad [\infty]$$

$\alpha$   $L^2$  parámetro de regularización

→ Decrecer los pesos con el gradiente

$$\Omega(\theta) = \frac{1}{2} \|w\|^2 \text{ de la función.}$$



$$W = (X^T X - \alpha I)^{-1} X^T y$$

HIPERPARÁMETRO DEL PESO DE LA SANCIÓN.

AUMENTO DEL CONJUNTO DE DATOS.




FAKE DATA.

DATOS LIMITADOS




→ Parada Anticipada


Todas las veces que el error sobre el conjunto de validación mejora, guardamos una copia del modelo de parámetros



Entrenamiento paralelo



DESERCIÓN:  
"DROPOUT" → REGULARIZA LOS MODELOS.



RN RN RN

EMBOLSADO

"BOOTSTRAP": TÉCNICA PARA REDUCIR EL ERROR DE GENERALIZACIÓN MEDIANTE LA COMBINACIÓN DE VARIOS MODELOS.

EN GENERAL: LA IDEA ES ENTRENAR VARIOS MODELOS (DIFERENTES) POR SEPARADO Y HACER QUE TODOS LOS MODELOS VOTEN SOBRE LA SALIDA PARA LOS EJEMPLOS DE PRUEBA (PROMEDIO).

ORIGINAL DATASET

9 6 8

FIRST RESAMPLED DATASET

8 6 8

SECOND RESAMPLED DATASET

9 9 8

FIRST ENSEMBLE MEMBER

9 → 8

SECOND ENSEMBLE MEMBER

0 → 8

EMBOLSADO

ENSAMBLE

