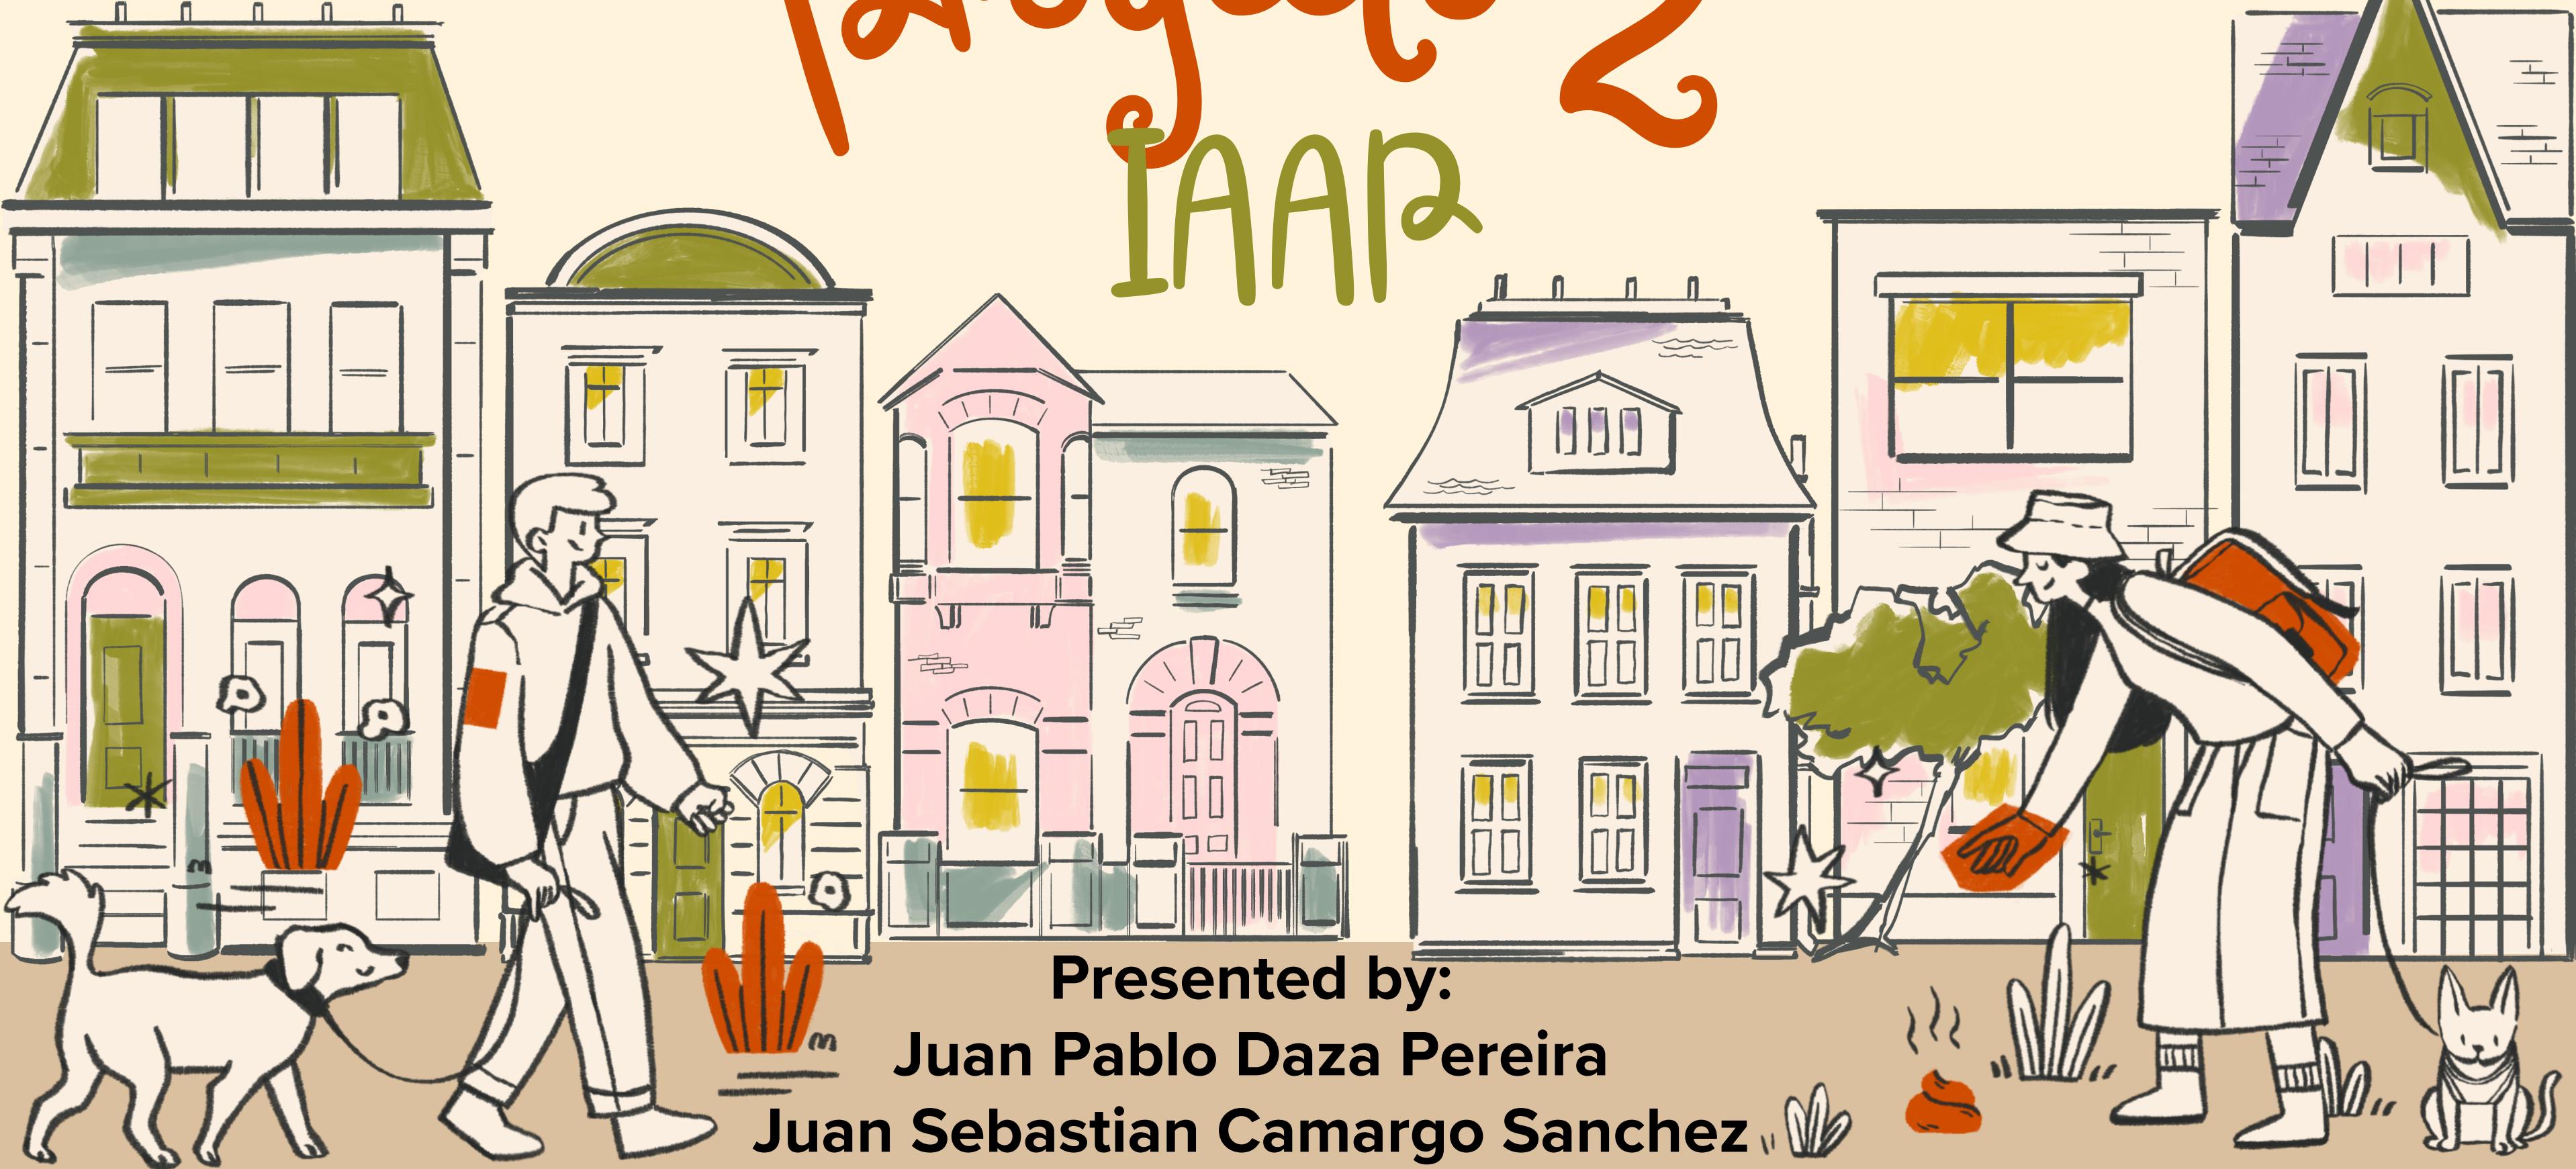


Proyecto 2

IAAP



Presented by:
Juan Pablo Daza Pereira
Juan Sebastian Camargo Sanchez

Dog or cat? What is it?





¿Cuál es el problema?

**CLASIFICACIÓN DE IMÁGENES DE
PERROS Y GATOS.**

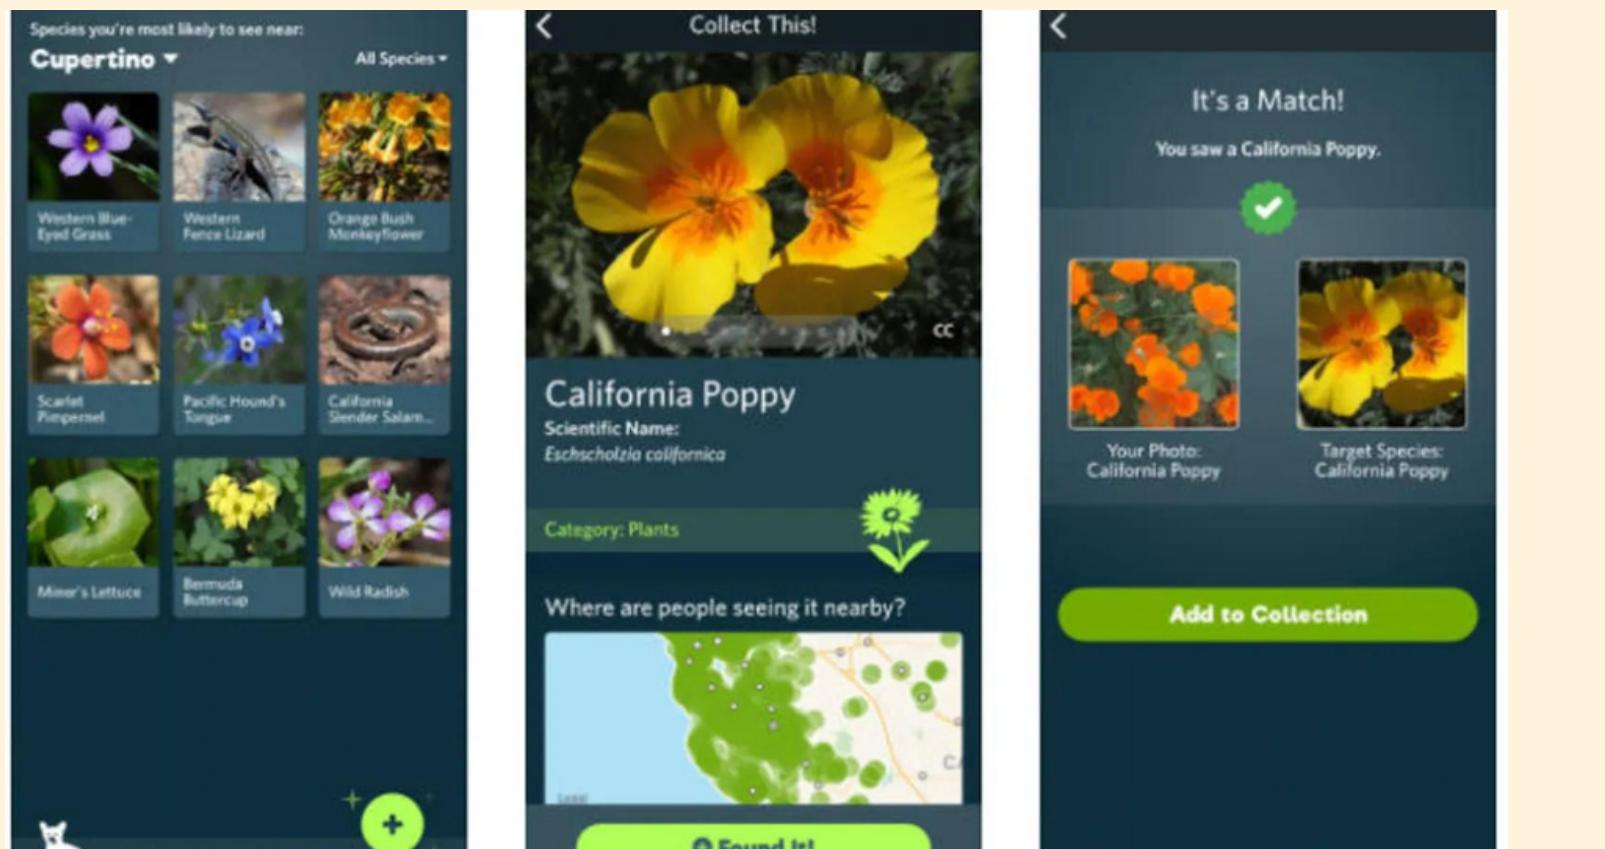


¿Por qué es importante resolverlo?



Sirve como un punto de partida fundamental para desarrollar y mejorar algoritmos de aprendizaje automático y técnicas de visión por computadora. Este problema enfrenta desafíos significativos debido a la variabilidad en la apariencia de ambas especies, incluyendo diferentes razas, poses, fondos y condiciones de iluminación. Al abordar este problema se pueden perfeccionar métodos de extracción de características, optimización de modelos y técnicas de entrenamiento, lo que conduce a avances más amplios en la clasificación de imágenes.

¿Qué se ha hecho al respecto? (Limitaciones)



**SEEK, EL “SHAZAM”
DE LA
NATURALEZA**

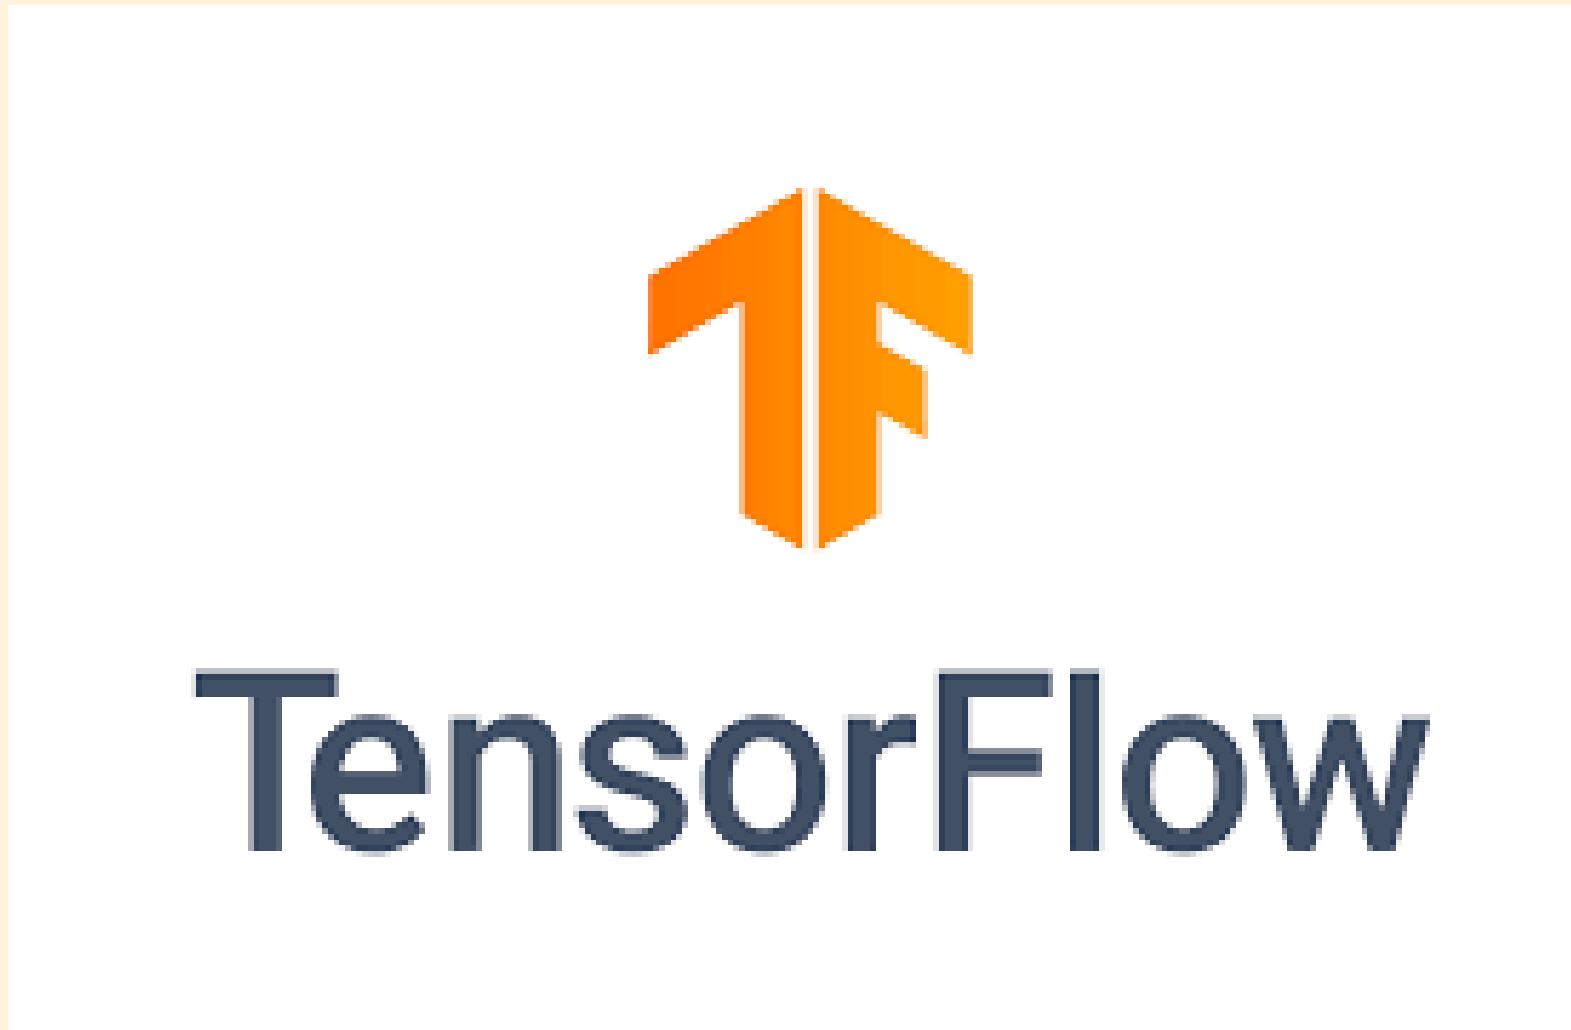


**RECONOCIMIENTO
DE OBJETOS**

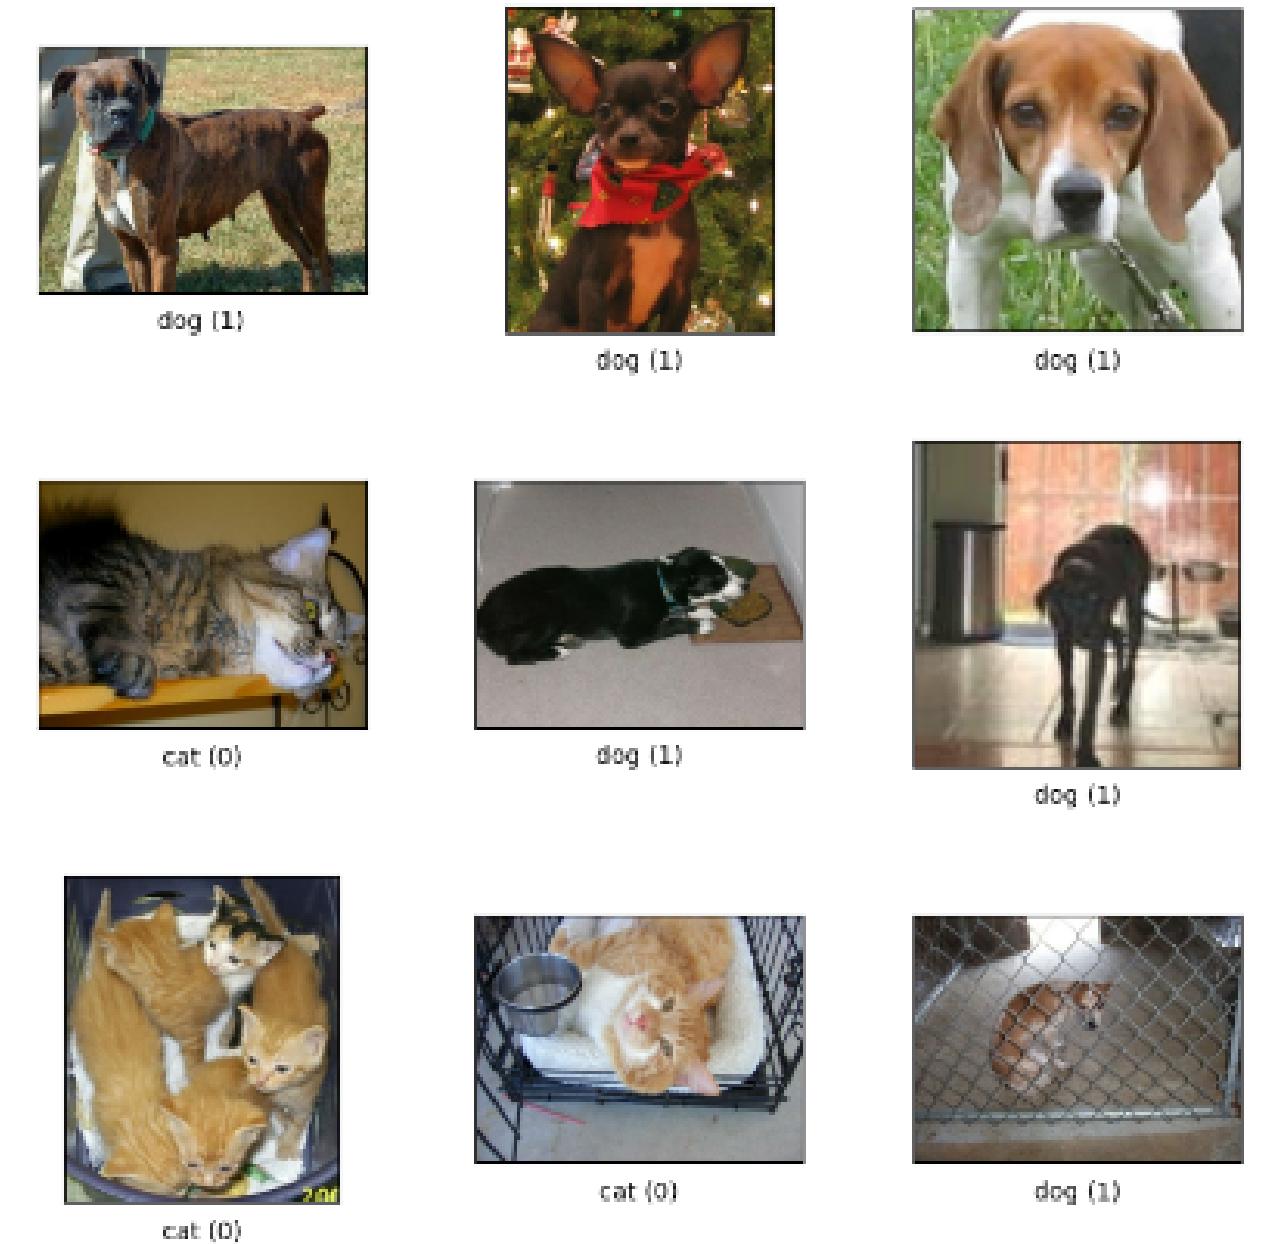
¿Cuál fue la idea de solución?



¿Cuál fue la idea de solución?



**TENSORFLOW
DATASETS**



GATOS_VS_PERROS

¿Cuál fue la idea de solución?



**DATASET
GATOS_VS_PERROS**

¿Cuál fue la idea de solución?



¿Cuál fue la idea de solución?

PLAN B

Entrenamiento de los
modelos

4

1

Aumento y
Manipulación
de datos

2

Preparación
de datos

3 Modelos:

- Denso
- CNN
- CNN plus

3

Arquitectura

¿Cuál fue la idea de solución?

4

El objetivo del proyecto es tener un resultado de
metricas mayores al 80%.

Entrenamiento de los
modelos

80% Train

10% Dev

10% Test

5

Escoger el mejor
modelo



Realizar pruebas con el modelo

¿Cuál fue la solución?



Experimentación en los modelos

Sobre la etapa de test



1. Manipulamos los datos de tal manera que se puedan manejar más fácil en porcentajes y más fáciles de procesar para las herramientas que disponemos . Disponemos de una imagen $150 \times 150 \times 1$.
2. Al probar en cada modelo propuesto (Denso. CNN. CNN plus) nos decidimos en enfocarnos en el modelo CNN por los resultados que tenía.
3. Entrenamos varios modelos CNN con diferentes arquitecturas y actualizando sus hiperparámetros hasta llegar a un buen modelo. Optimizamos con mini batch y cambios de arquitectura e hiperparametros.

Modelo

- Capa Convolucional 1:

Filtros: 32

Tamaño del filtro: 3x3

Función de activación: ReLU

Entrada: Imágenes de tamaño (tamaño img. tamaño img. 1) (escala de grises)

- Capa de Pooling 1:

Tipo: Max Pooling

Tamaño del filtro: 2x2

- Capa Convolucional 2:

Filtros: 64

Tamaño del filtro: 3x3

Función de activación: ReLU

Realiza más convoluciones para aprender características más complejas.

- Capa de Pooling 2:

Tipo: Max Pooling

Tamaño del filtro: 2x2

- Capa Convolucional 3:

Filtros: 128

Tamaño del filtro: 3x3

Función de activación: ReLU

- Capa de Pooling 3:

Tipo: Max Pooling

Tamaño del filtro: 2x2

Reduce aún más la resolución espacial.

- Capa Convolucional 4:

Filtros: 256

Tamaño del filtro: 3x3

Función de activación: ReLU

- Capa de Pooling 4:

Tipo: Max Pooling

Tamaño del filtro: 2x2

- Capa Flatten:

Transforma las características en un vector unidimensional.

- Capa Densa :

Neuronas: 400

Función de activación: ReLU

- Capa Densa de Salida:

Neurona única

Función de activación: Sigmoid

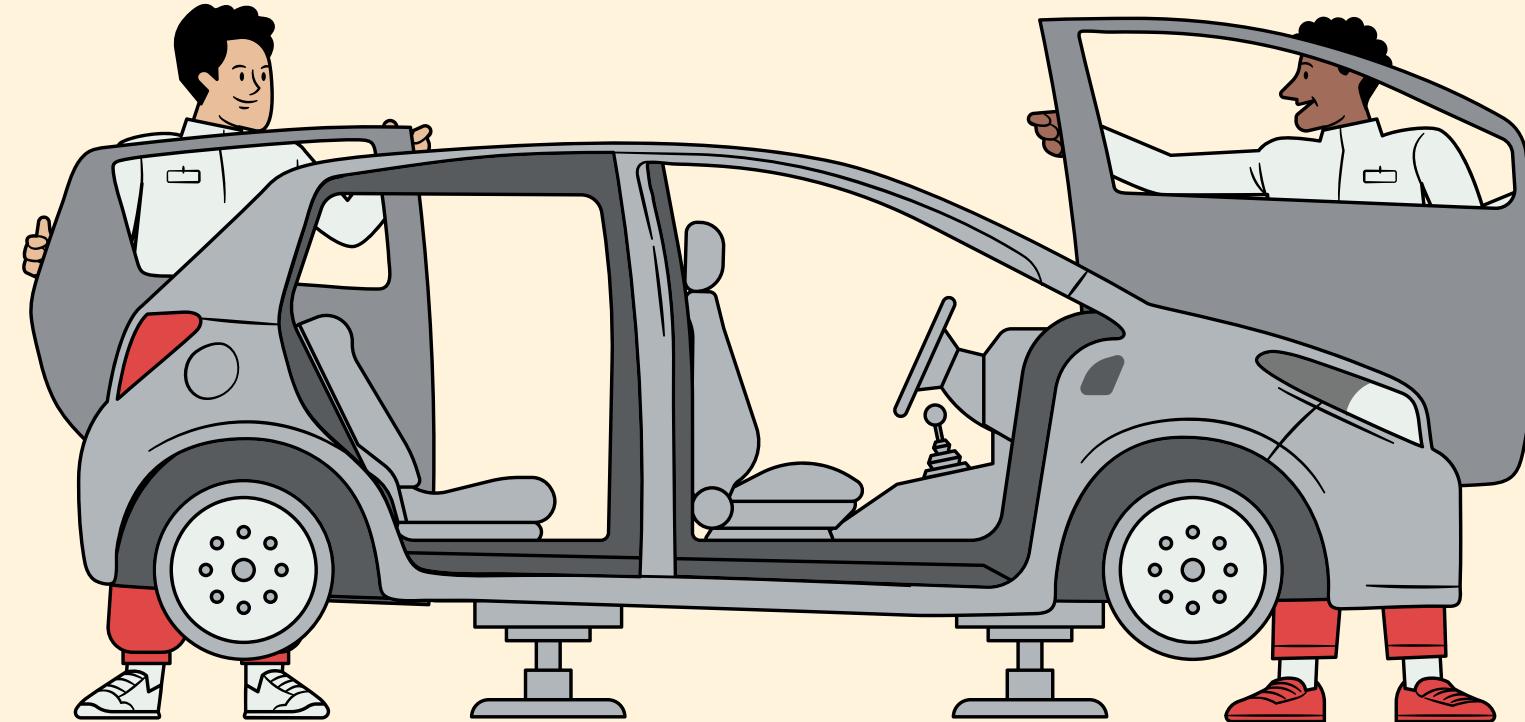
Produce una predicción binaria



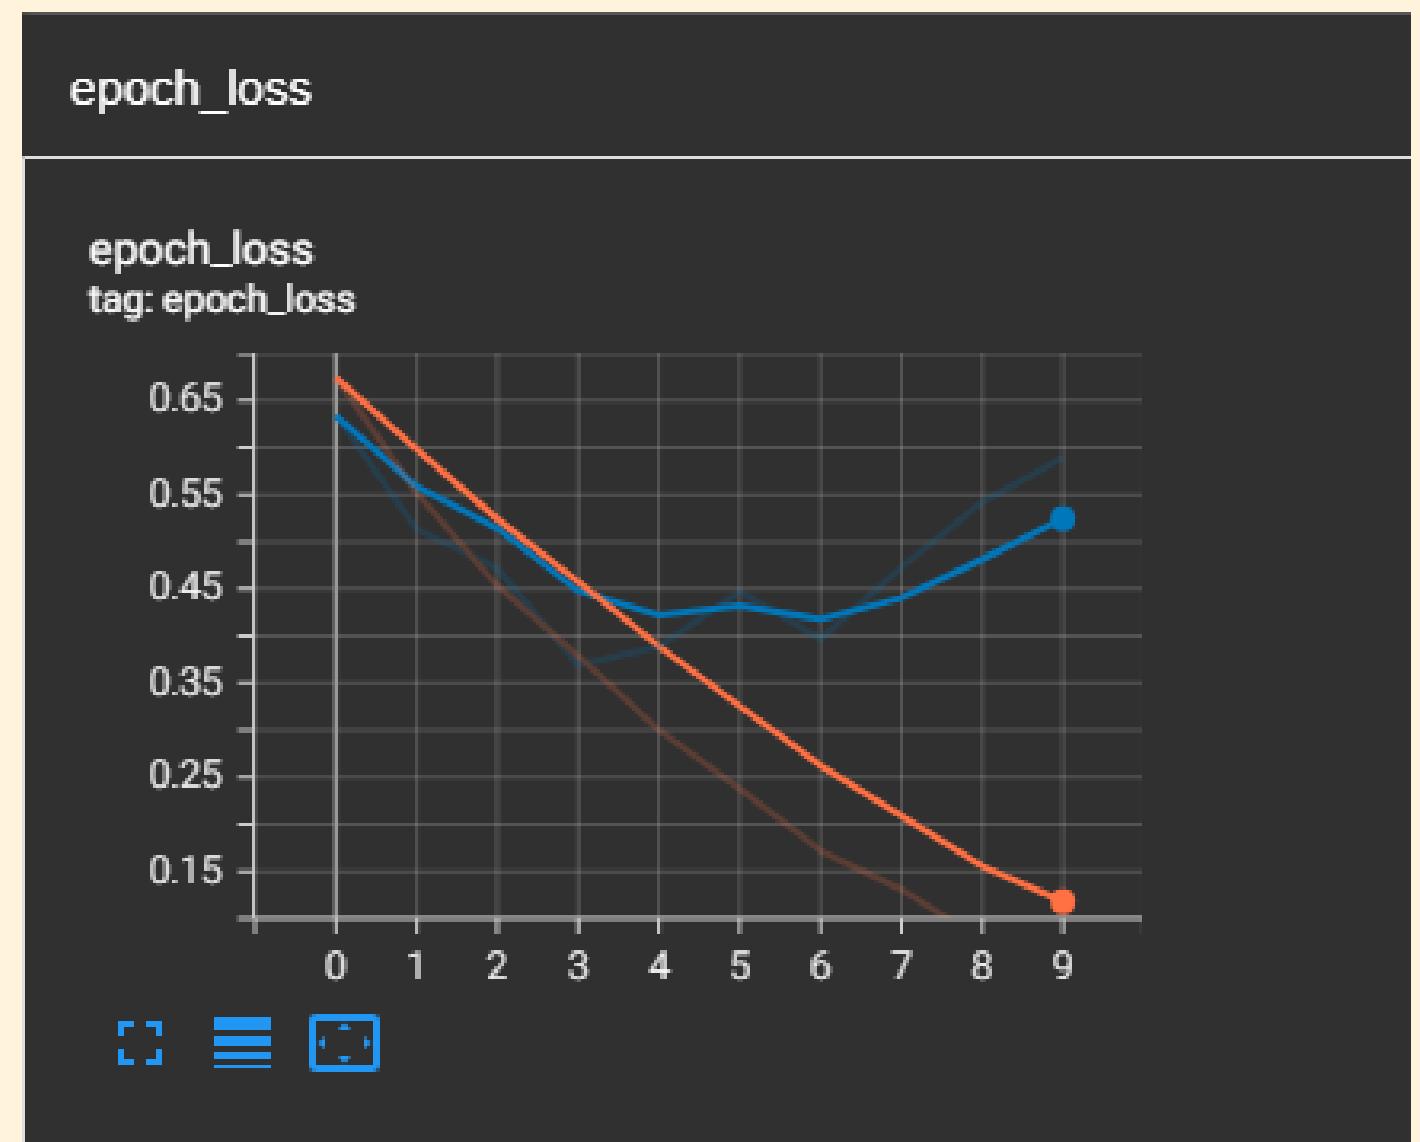
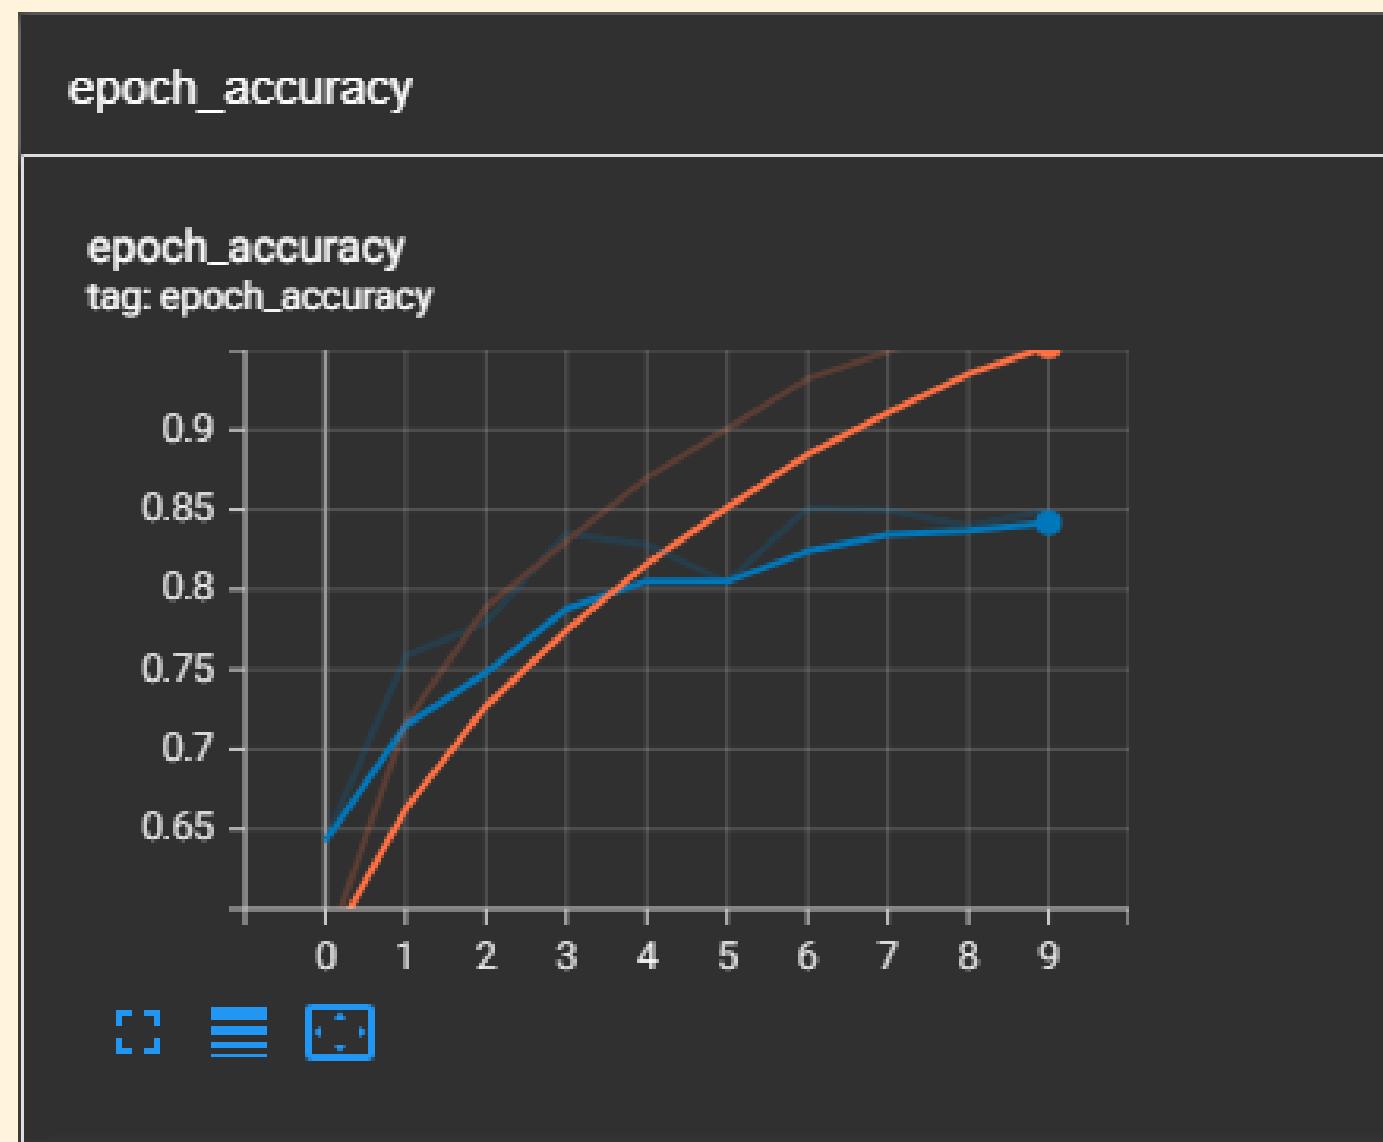
Sobre la etapa de dev

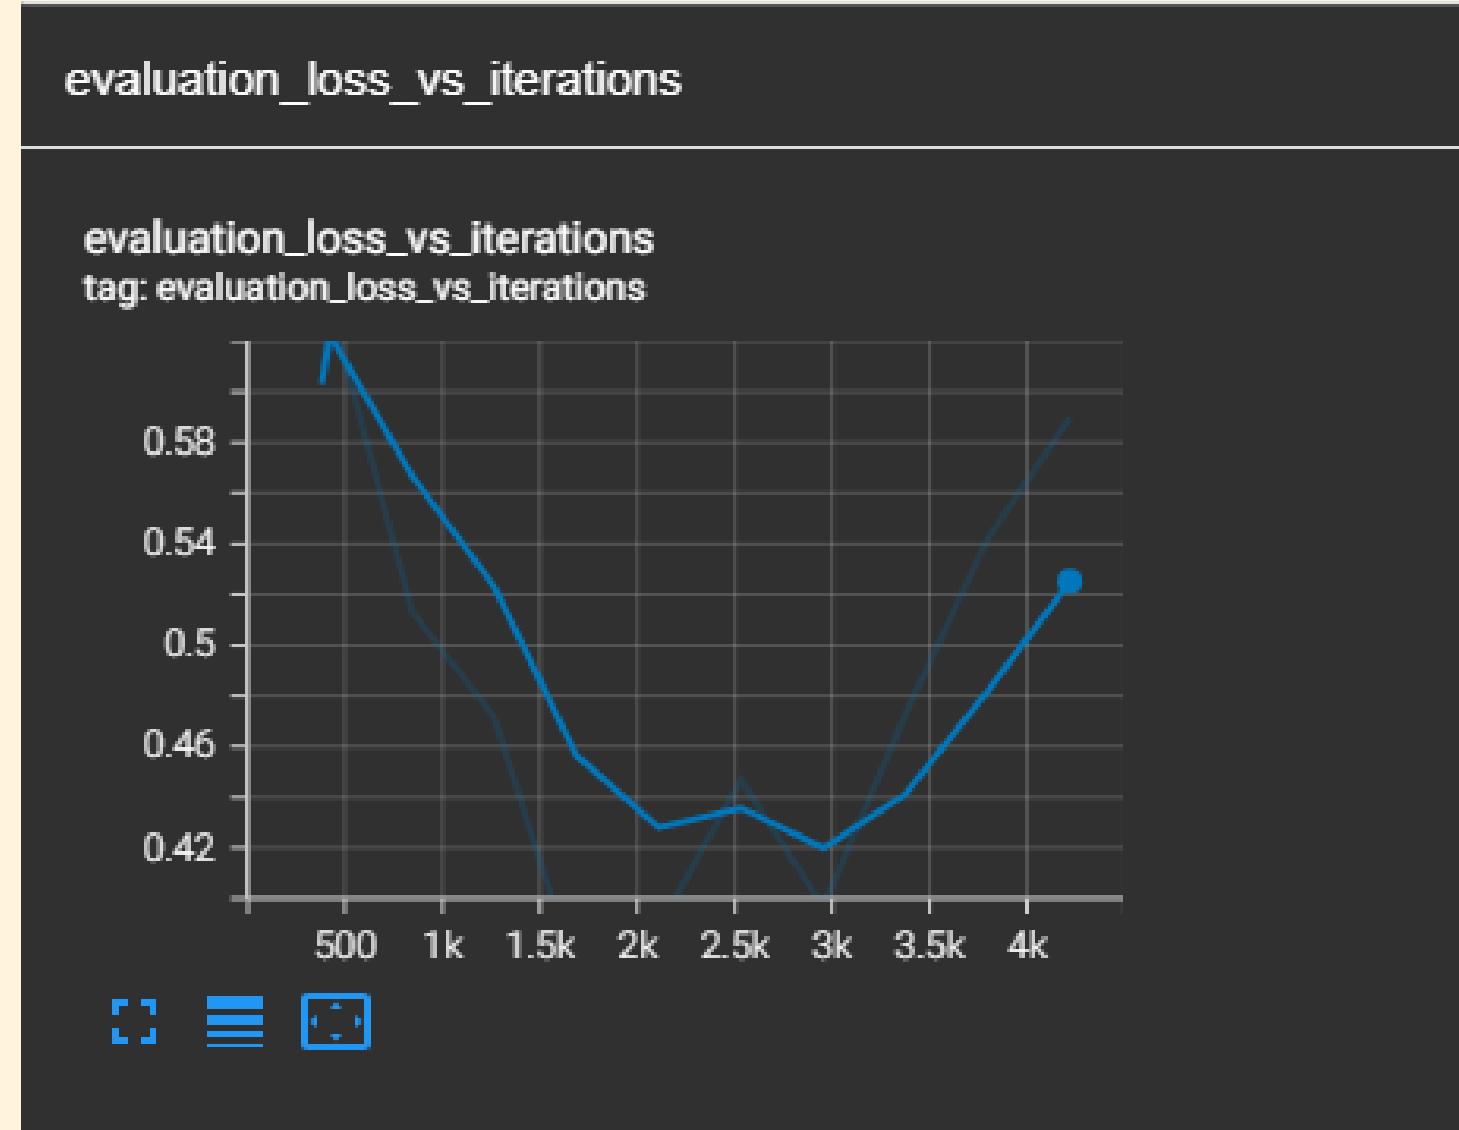
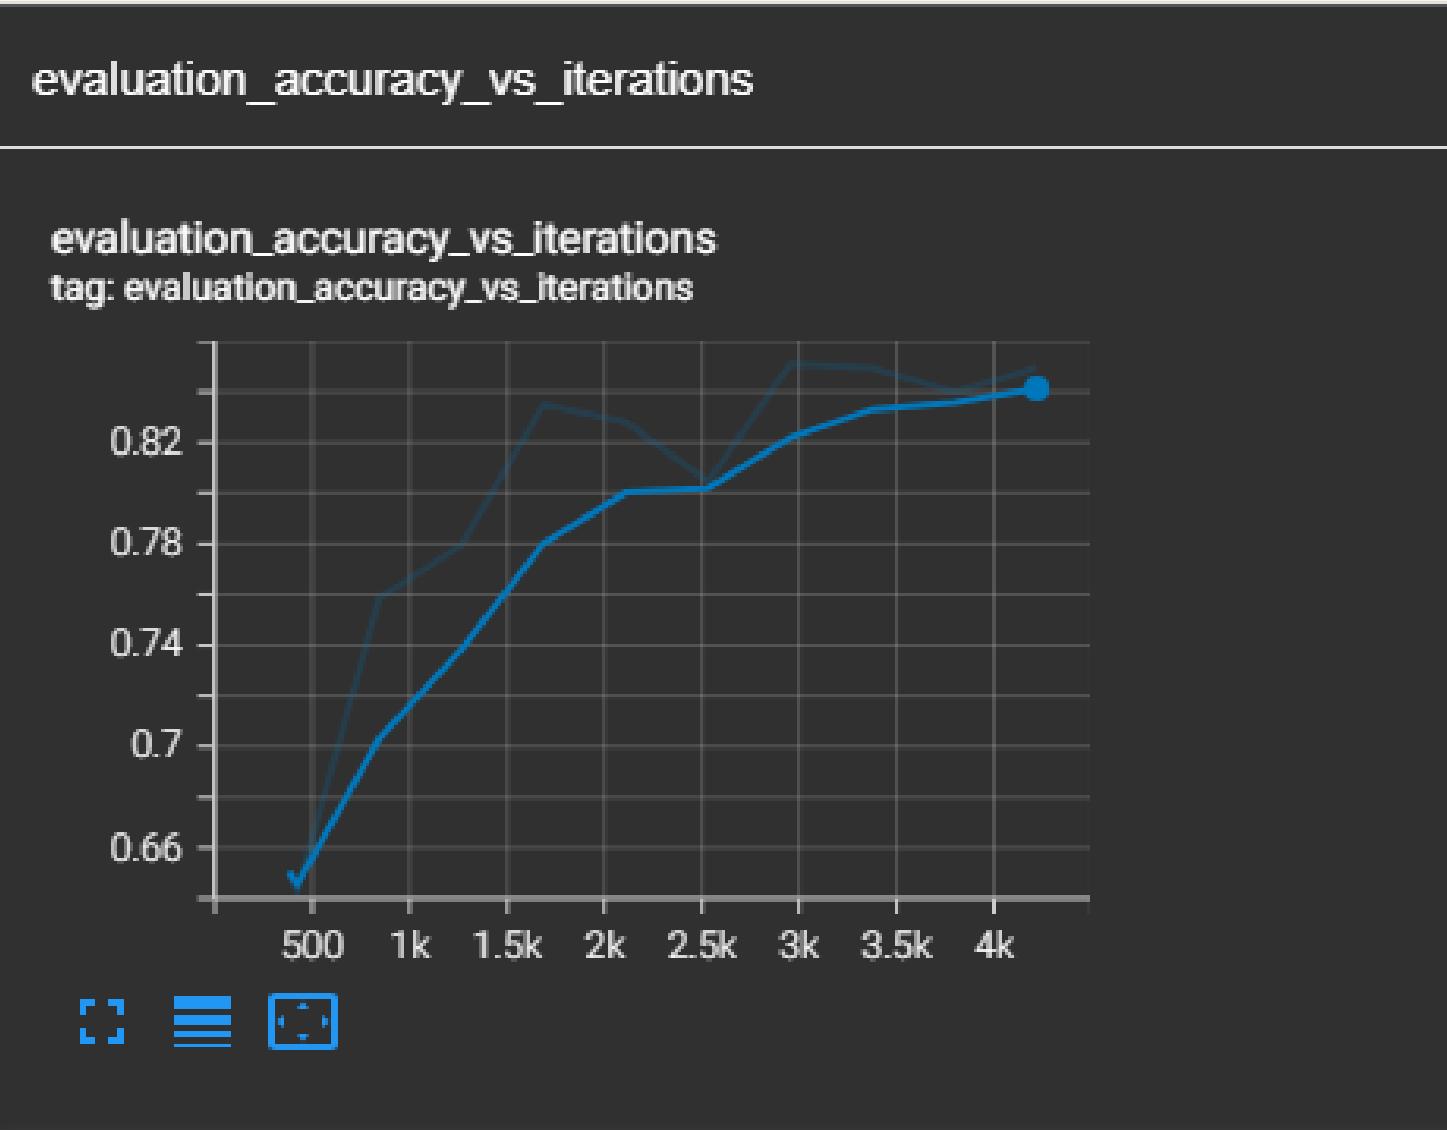
1. Ya sobre esta etapa el framework nos permite ir verificando con el modelo con los datos de validación y su comportamiento. De esa manera aplicamos una leve regulariazacion de Dropout en la red densa del modelo del

0·1.



Gráficas del comportamiento sobre la etapa de desarrollo





Sobre la etapa de Test



1. Verificamos que nuestro modelo esté regularizado y optimizado y cumpla nuestros objetivos.
2. Evaluamos si el plan B es necesario. No lo fue

¿Qué resultados han obtenido?



Sobre las métricas que tuvimos

En general, los resultados son bastante buenos, especialmente considerando que la métrica objetivo era del 80%. El modelo logra un rendimiento sólido en la clasificación de perros y gatos en el conjunto de prueba.

1. Accuracy: 0.8565
2. Precision: 0.84
3. Recall: 0.88
4. F1 Score: 0.86



¿Qué podemos aprender de los resultados?

Sería útil analizar más a fondo los errores específicos que comete el modelo para identificar posibles áreas de mejora. Además, es importante considerar otros factores como el sesgo y la variabilidad en los datos de entrenamiento y prueba.

Efectividad → Manipulación de datos

Montaje de varios modelos → Generalización del modelo

¿Cuáles son las contribuciones principales?



DESARROLLO DE UN MODELO EFECTIVO

Se desarrolló un modelo que es capaz de distinguir con precisión entre imágenes de gatos y perros.



TÉCNICAS DE PROCESAMIENTO DE IMÁGENES

Innovación en técnicas de procesamiento de imágenes que permitan extraer características relevantes de las imágenes de gatos y perros.



GENERALIZACIÓN ROBUSTA

El modelo probablemente puede ser capaz de clasificar con precisión imágenes que no ha visto durante el entrenamiento.

¿Cuáles son las líneas de trabajo futuro?

MEJORA DE LA PRECISIÓN DEL MODELO

Una línea de trabajo importante sería mejorar la precisión de los modelos existentes. Esto podría lograrse mediante el uso de arquitecturas de redes neuronales más avanzadas, técnicas de regularización más efectivas y aumento de datos.



EXPLORACIÓN DE NUEVAS ARQUITECTURAS DE REDES NEURONALES

Se podría investigar y desarrollar arquitecturas de redes neuronales específicamente diseñadas para la clasificación de imágenes de animales.



DESARROLLO DE CONJUNTOS DE DATOS MÁS DESAFIANTES

Esto podría incluir la incorporación de imágenes en condiciones difíciles, como baja iluminación, imágenes borrosas para mejorar la capacidad del modelo para generalizar a una amplia variedad de escenarios.



Gracias por su atención



Referencias



TensorFlow

gatos_vs_perros | TensorFlow Datasets

Un gran conjunto de imágenes de perros y gatos. Se eliminan 1738 imágenes corruptas.



TensorFlow